

# Research proposal

## 1. Hipoteza

Model tile2vec jest w stanie generować semantycznie istotne mapowanie, ale nie jest w tym dostatecznie dobry i jego działanie można poprawić.

## 2. Jakość standardowego modelu

Weryfikacja sposobu uczenia modelu za pomocą prostych metod wyjaśnialności - przetestowanie poprawności działania dla poszczególnych aspektów praktycznych, przy wykorzystaniu różnych kombinacji bandów.

## 3. Ulepszenie standardowego modelu

Być może model nie funkcjonuje dobrze, gdyż aktualny objective - triplet loss nie jest dostatecznie dobrze dostosowany do naszych danych.

## 4. Eksperymenty

1. Trenowanie modelu dla poszczególnych kombinacji i przekształceń bandów odpowiadających różnym zastosowaniom praktycznym, na przykład:

1. Color Infrared ( $B8, B4, B3$ )

Pozwala badać wegetację roślin, działa ona odpowiednio do wykrywania chlorofilu.

2. Agriculture ( $B11, B8, B2$ )

Pozwala ocenić jakość upraw.

3. Vegetation Index  $(B8 - B4)/(B8 + B4)$

Znormalizowany wskaźnik wegetacji, wysokie wartości sugerują gęstą roślinność, niskie lub ujemne wskazują na obszary miejskie i wodne.

4. Moisture Index  $(B8A - B11)/(B8A + B11)$

Wykrywamy poziom wilgoci.

Naszym celem jest weryfikacja, w jakim zastosowaniu możemy najskuteczniej wykorzystać nasz model w praktyce i zbadać czy mapowanie generowane przez model faktycznie wykorzystuje informacje zawarte w bandach

Osoby odpowiedzialne za zadanie: Natalia, Maciek, Filip

## 2. Hard-negative mining

Aby wykorzystać opisy zdjęć naszego datasetu Eurosat, spróbujemy "wspomóc" unsupervised triplet loss przez dodanie dodatkowej informacji o klasie płytek.

Osoba odpowiedzialna: Łukasz

## 3. Contrastive learning

Głównym założeniem obecnym w danych jest podobieństwo płytek które są blisko siebie. Jednak aby wykorzystać informacje o lokalizacji płytek względem siebie, należałoby posiadać albo bardzo duże zdjęcia pokrywające znaczne obszary, albo wykorzystać geolokalizację zdjęć i na tej podstawie porównywać ze sobą płytki. Ponieważ jednak w naszym zbiorze płytki nie pochodzą z jednego obszaru i mają bardzo mały rozmiar zdecydowaliśmy się zmodyfikować objective modelu i zweryfikować czy model wykorzystujący zwykły contrastive loss dla pary obrazków będzie sprawował się lepiej niż ten wykorzystujący triplet loss

Osoba odpowiedzialna: Tymek

# 5. Jak zmierzmy, czy się udało - ewaluacja

1. Jakość (acc) klasyfikatora wytrenowanego na wytworzonych cechach - embeddingach
2. Jakość (vmeasure, silhouette score) klasteryzacji na wytworzonych cechach - embeddingach
3. Wizualizacja embeddingów za pomocą tSNE - wizualna ocena jakości klastrów

Z uwagi na specyficzne zadanie w 1 ścieżce planujemy zmierzyć jakość mapowania w dodatkowy sposób:

Porównujemy accuracy dla różnych labeli przy wykorzystaniu poszczególnych, oddzielnie wytrenowanych modeli. Sprawdzamy, czy na przykład przeprowadzając badanie dla modelu color\_infrated lepiej są przewidywane obrazy zawierające pola uprawne.